

Easyedit

1. **An Easy-to-use Knowledge Editing Framework for Large Language Models**

(2024) 대규모 언어 모델을 위한 사용하기 쉬운 지식 편집 프레임워크


2. **An Easy-to-use Steering Framework for Editing Large Language Models**

(2025) 대규모 언어 모델 편집을 위한 사용하기 쉬운 스티어링 프레임워크

Easyedit1: An Easy-to-use Knowledge Editing Framework for LLM

(1) What is the literature gap

Knowledge Editing



- **Knowledge Storage Mechanism**과 함께 발전한 개념
 - “LLMs can be conceptualized as knowledge banks, and the transformer MLP layers function as key-value memories.”
 - **Knowledge Localization**: LLM 내부에서 특정 사실이나 개념이 어떤 뉴런/레이어에 저장되어 있는지를 찾는 과정
- LLM에 저장된 지식을 중 일부를 수정하고 나머지 지식을 보존하는 기술

Easyedit1: An Easy-to-use Knowledge Editing Framework for LLM

(1) What is the literature gap

Knowledge Editing Method

1. Memory-based

- 모델의 매개변수를 직접 수정하지 않고, 편집할 지식이나 사실을 외부 저장소에 저장하는 방식

2. Meta-learning

- 새로운 지식에 대한 매개변수 변화량을 예측하거나 생성하여, 원래 모델의 가중치에 더하는 방식

3. Locate-then-Edit

- 모델 내부에서 편집할 지식이 저장되어 있는 특정 뉴런/매개변수를 찾고, 해당 위치의 매개변수를 직접 수정하는 방식

The Literature Gap

- 다양한 지식 편집 기법들 → 구현 방식 다양하고, 실험 설정(모델 구조, 입력/출력 포맷, 편집 절차 등) 일관적이지 않음
 - 서로 비교하기 어려움
 - 지식편집기법들을 시험해보기 어려움
- 지식 편집 기법을 실제 응용 시스템에 도입하기에는 복잡성, 사용 편의성, 안정성 등의 장벽이 존재

(2) What is new in this work



- **Easyedit**: 다양한 지식 편집 기법들을 하나의 통합된 프레임워크로 묶은 쉬운 사용성 툴킷을 제안
 - 여러 LLM 구조(T5, GPT-J, LLaMA 등)에 대해 적용 가능하도록 **portability** 확보
 - 지식편집 수행 절차를 **통일된 API**(ex. edit(), apply_to_model()) 형태로 감쌈
 - 지식편집 작업에 대한 **평가모듈** 제공

```
# Step 1: Choose the Editing Method e.g. MEND
from easyeditor import BaseEditor
from easyeditor import MENDHyperParams
hparams = MENDHyperParams.from_hparams('gpt2-xl.yaml')

# Step 2: Provide the edit descriptor and target
prompts = ['Q: The president of the US is? A:',]
target_new = ['Joe Biden']
rephrase_prompts = ['The leader of the United State is']

# Step 3: Combine them into the `BaseEditor`
editor = BaseEditor.from_hparams(hparams)

# Step 4: Edit and Evaluation
metrics, edited_model = editor.edit(
    prompts=prompts,
    target_new=target_new,
    keep_original_weight=True,
)


# metrics: Performance of knowledge editing
# edited_model: Model after modifying the weights
```

LLM 모델: gpt2 모델, **Knogwledge Editing 기법:** Meta-learning(MEND)

Easyedit1: An Easy-to-use Knowledge Editing Framework for LLM

(3) How is the gap filled

Easyedit Architecture



- **User Demand**

- **x_e** : 편집 설명자(입력 인스턴스) ex. 미국 대통령 누구인가?
- **y_e** : 편집 목표(원하는 출력) ex. 조 바이든
- **model_hparams**: 편집 대상 모델과 관련된 하이퍼파라미터 ex. 수정할 레이어 수

- **Editor**

- EasyEdit 프레임워크의 핵심 & 직접적인 진입점 역할
- 위 사용자의 입력을 받아 다양한 지식 편집 시나리오(ex. 단일 인스턴스, 배치, 순차, 멀티모달 편집)를 수행함

- **Method**

- 3가지 지식편집(memory, locate-then-edit, meta-learning) 방법 지원

- **Evaluate**

- **Reliability**: 편집된 사실이 해당 문장에서 잘 반영되었는가?
- **Generalization**: 수정된 사실이 다른 표현에서도 일관되게 반영되는가?
- **Locality**: 관련 없는 문장에는 영향이 없는가?
- **Portability**: 편집된 지식이 연관된 다른 문맥으로 자연스럽게 전파되는가?
- **Fluency**: 시간/자원 대비 얼마나 빠르고 간단히 수정되는가?

Easyedit1: An Easy-to-use Knowledge Editing Framework for LLM

(4) What is achieved with the new method

	Reliability	Generalization	Locality	Portability	Fluency
FT-L	56.94	52.02	96.32	51.03	488.41
SERAC	99.49	99.13	100.00	57.82	423.22
IKE	100.00	99.98	69.19	67.56	557.37
MEND	94.24	90.27	97.04	56.95	540.06
KN	28.95	28.43	65.43	37.18	478.32
ROME	92.45	87.04	99.63	57.47	587.58
MEMIT	92.94	85.97	99.49	60.64	576.51
GRACE	99.22	0.43	100.00	56.87	426.31

- Memory-based: SERAC, GRACE, IKE
- Meta-learning: KE, MEND
- Locate-then-edit: KN, ROME, MEMIT, PMET

LLaMA-2 7B 모델, ZsRE(Zero-shot Relation Extraction) 데이터셋 기준 실험

- fine-tuning 대비 knowledge editing 장점
 - 지식 편집 방법들이 전통적인 fine-tuning 방식보다 더 안정적이고 일반화가 잘 되는 경우가 많음을 보여줌
- 지식편집 기법들의 성능 비교 결과
 - SERAC, IKE 등이 좋은 reliability/ generalization 점수를 내고, ROME, MEMIT 등도 다양한 균형 있는 성능을 보임