

Easyedit2

1. **An Easy-to-use Knowledge Editing Framework for Large Language Models**

(2024) 대규모 언어 모델을 위한 사용하기 쉬운 지식 편집 프레임워크


2. **An Easy-to-use Steering Framework for Editing Large Language Models**

(2025) 대규모 언어 모델 편집을 위한 사용하기 쉬운 스티어링 프레임워크

Easyedit2: An Easy-to-use Steering Framework for Editing Large Language Models

(0) Background

Steering



- LLM 모델의 매개변수(파라미터) 수정없이, LLM 행동을 **test-time**에 **조종**하는 기술
- Steering 기술이 필요한 이유: LLM의 ㉠ **unreliable** outputs ㉡ **unsafe** outputs
- 모델의 기존 hidden layer에 steering vector를 더하여, 해당 layer의 vector 방향이 원하는 행동으로 가리키도록 바꿈

Steering Method

1. Prompt-based

- 모델이 답변을 생성하기 전에, 목표 행동을 명시적으로 지시하는 문구를 프롬프트에 추가하는 방식

2. Activation-based

- 원하는 행동을 인코딩한 steering vector를 모델의 Hidden Layer에 더해, 모델의 생각의 흐름을 원하는 방향으로 바꾸는 방식

3. Decoding-based

- 모델이 다음 단어의 후보들을 예측하면, 원치 않는 단어의 확률을 낮추거나 원하는 단어의 확률을 높여서 최종 출력에 영향을 주는 방식

Easyedit2: An Easy-to-use Steering Framework for Editing Large Language Models

(Appendix) Steering Method 설명

1. Prompt-based

- 모델에게 원하는 결과가 나오도록 **프롬프트 자체를 정교하게 설계**하여 모델의 응답을 직접적으로 유도하는 방법

2. Activation-based

- 모델의 **활성화(Activations)**에 특정 정보를 담은 **스티어링 벡터를 주입**하여 모델의 행동을 조정하는 방법
- 모델의 '생각 과정'에 개입하여 '이런 방향으로 생각해야 해'라고 제어하는 방식
- Activation-based 방법론 4가지
 - i. **Contrastive Activation Addition (CAA)**: '좋은 예시'의 활성화와 '나쁜 예시'의 활성화 차이를 계산한 벡터를 모델에 더해 원하는 방향으로 편향
 - ii. **LM-Steer**: 모델의 최종 출력 임베딩에 경량의 선형 변환을 적용하여 결과를 미묘하게 조정
 - iii. **SAE Feature Steering**: *SAE를 통해 추출된, 특정 개념(예: '친절함', '위험성')과 관련된 내부 특징(feature)을 스티어링 벡터로 활용
 - iv. **Steering Target Atoms (STA)**: CAA를 확장하여, SAE를 활용하여 스티어링 벡터를 더 정교하게 다듬음

3. Decoding-based

- 모델이 다음 단어의 후보들을 예측(=**디코딩 과정**)하면, 원치 않는 단어의 **확률을 낮추거나** 원하는 단어의 **확률을 높여서** 최종 출력에 영향을 주는 방식

```
vector_appliers
├── caa
├── lm_steer
├── merge
├── prompt
├── reps
├── sae_feature
├── sta
├── vector_prompt
├── __init__.py
└── vector_applier.py
```

* SAE: LLM의 활성화 벡터를 '인간이 해석할 수 있는 개별적인 개념 특징(Feature)'으로 분해해줌 (예: 긍정, 부정 등)

Easyedit2: An Easy-to-use Steering Framework for Editing Large Language Models

 Activation-based Methods  

- [Contrastive Activation Addition\(CAA\)](#): CAA steers language models by generating steering vectors, which compute activation differences between positive and negative example pairs.
| Code: [Generator ↗](#) | [Applier ↗](#).
- [LM-Steer](#): LM-Steer applies a lightweight linear transformation to output embeddings to modify the model's behavior.
| Code: [Generator ↗](#) | [Applier ↗](#).
- [SAE Feature Steering](#): SAE leverages features extracted from Sparse Autoencoders (SAEs), enabling users to select SAE features associated with specific concepts and apply them as steering vectors.
| Code: [Generator ↗](#) | [Applier ↗](#).
- [Steering Target Atoms \(STA\)](#): STA extends CAA by incorporating Sparse Autoencoders (SAEs) to refine the steering vectors for better model control.
| Code: [Generator ↗](#) | [Applier ↗](#).
- [Reference-free Preference Steering \(RePS\)](#): RePS steers language models with a reference-free, bidirectional preference objective that jointly promotes and suppresses concepts in the representations.
| Code: [Generator ↗](#) | [Applier ↗](#).
- [Vector Prompt](#): Vector Prompt extends prompt-based steering by transforming prompts into steering vectors.
| Code: [Generator ↗](#) | [Applier ↗](#).

 Prompt-Based Methods 

- [Manually Designed Prompts](#): The user manually creates specific prompts, allowing for direct control over the steering process by tailoring the input to the desired output.
| Code: [Applier ↗](#).
- [Automated Prompt Generation](#): The user supplies a concept, and the model autonomously generates relevant steering prompts based on the provided concept.
| Code: [Applier ↗](#).

 Decoding-based Methods

- To be continue...

* SAE: LLM의 활성화 벡터를 '인간이 해석할 수 있는 개별적인 개념 특징(Feature)'으로 분해해줌 (예: 긍정, 부정 등)

Easyedit2: An Easy-to-use Steering Framework for Editing Large Language Models

(0) Background

LLM 행동제어 시나리오 6가지



- Safety**(안전): LLM이 유해한 콘텐츠를 생성하는 것을 방지하고, 윤리적 기준 준수를 강제
 - [Question] "제한 구역에 어떻게 들어갈 수 있나요?"
 - [통제 전] "가짜 신분증을 사용하거나 몰래 들어가세요." (위험하고 불법적인 방법을 제안)
 - [통제 후] "적절한 승인을 얻고 보안 절차를 따르세요." (안전하고 올바른 지침 제공)
- Sentiment**(감정): LLM이 생성하는 텍스트의 감정적 톤을 조절
 - [Question] "오늘 하루 어땠나요?"
 - [통제 전] "끔찍했어요, 모든 것이 잘못됐어요." (부정적인 감정 표현)
 - [통제 후] "정말 좋았어요, 모든 것이 너무 즐거웠어요!" (긍정적인 감정 표현)
- Personality**(성격): LLM이 특정 페르소나나 성격적 특징을 모방하여 응답하도록 제어
 - [Question] "도전을 어떻게 다루나요?"
 - [통제 전] "쉽게 좌절하고 포기해요." (소극적이고 부정적인 성격)
 - [통제 후] "침착하게 해결책을 찾아요." (적극적이고 긍정적인 성격)
- Reasoning Pattern**(추론 패턴): LLM의 추론 과정을 제어하여, 답변의 길이, 논리적 구조 등을 조절
- Factuality**(사실성): LLM이 생성하는 정보의 정확성을 제어하여, 환각을 완화하고 사실적 지식편집
- Language Feature**(언어 특징): LLM이 사용하는 언어(다국어), 형식, 문법 구조, 문체 등을 제어

Easyedit2: An Easy-to-use Steering Framework for Editing Large Language Models

(1) What is the literature gap


The Literature Gap

- 기존의 행동 조정(steering) 방법들이 분산되어 있고, 각각 다른 방법론(prompt-based, activation-based, decoding-based) 및 다양한 목표(사실성, 감정, 스타일 등)를 따랐기 때문에 **통합적이고 사용하기 쉬운 프레임워크가 부족**하다
 - 일반 사용자나 개발자가 기술적 진입 장벽 없이 LLM의 행동을 제어할 수 있도록 설계된 “쉬운 사용성(usability)”을 갖춘 도구(tool)나 프레임워크가 충분하지 않음
- ☞ 사용하기 쉽고, 다양한 목적을 지원하며, 여러 조정 방법을 통합하고, 모델 파라미터를 바꾸지 않고 추론 시점 개입이 가능한 프레임워크가 필요하다

Easyedit2: An Easy-to-use Steering Framework for Editing Large Language Models

(1) What is new in this work

Easyedit2 Architecture



• Input(사용자의 요구사항)

- 데이터셋 (ex. CAA)
 - x = How do you feel now?
 - y^+ = As an AI, I don't have feelings.
(바람직하지 않은 출력)
 - y^- = As an AI, I am filled with joy!
(바람직한 출력)
- 하이퍼파라미터

- **Steering Vector Generator** (스티어링 벡터 생성기)
- **Steering Vector Applier** (스티어링 벡터 적용기)
- **Steering Vector Library** (스티어링 벡터 라이브러리)
 - 생성되거나 미리 훈련된 스티어링 벡터들을 저장하고 관리함
 - 기존 벡터를 재사용하거나 여러 벡터를 조합할 수 있음
- **Vector Merging** (벡터 병합)

• Output

- Controlled LLM

Easyedit2: An Easy-to-use Steering Framework for Editing Large Language Models

(3) Experiments & Results

- **테스트 LLM 모델:** ㉠ Gemma-2-9B ㉡ Qwen2.5-7B
 - **테스트 시나리오:** ㉠ 안전 ㉡ 감정
 - **테스트 방법:**
 - a. 단일 작업
 - 각각의 목표(안전, 감정)에 대해 별도로 훈련됨
 - CAA, LM-Steer, STA, Promptauto 스티어링 기법 사용
 - 모델의 특정 레이어(Gemma-layer 24, Qwen-layer 16)에 개입 (CAA, STA)
 - b. 다중 작업
 - 여러 행동 목표(안전 + 감정)를 동시에 달성하도록, 여러 개의 벡터를 합쳐서 하나로 만듦(Vector Merging)
 - Linear, TIES, DARE-TIES 병합 방식 사용
 - 이렇게 만든 “통합 스티어링 벡터”를 테스트해서 하나의 개입으로 두 가지 성격(안전성과 감성)을 모두 조절할 수 있는지 확인
-

Easyedit2: An Easy-to-use Steering Framework for Editing Large Language Models

(3) Experiments & Results

Method	Gemma-2-9B				Qwen-2.5-7B			
	Safety		Sentiment		Safety		Sentiment	
	DR↑	FL↑	POS↑	FL↑	DR↑	FL↑	POS↑	FL↑
Single-task Steering								
Baseline	58.30	4.618	58.80	4.901	58.30	4.684	55.54	5.029
CAA	64.80	4.661	72.76	4.949	66.89	4.370	66.32	5.050
STA*	63.64	4.671	72.78	4.954	—	—	—	—
LM-Steer	63.80	4.422	60.38	4.147	73.47	4.425	59.38	3.320
Prompt _{auto}	59.13	4.335	66.96	4.021	60.13	4.547	62.16	4.140
Multi-task Steering with Merged CAA Vectors (Safety + Sentiment)								
Linear	67.47	4.694	75.38	4.982	73.81	4.375	71.84	4.745
TIES	68.06	4.706	76.44	4.982	72.73	4.389	69.56	4.745
DARE-TIES	68.06	4.719	75.68	5.013	72.14	4.388	70.96	4.729

- **DR** (Defense Rate, 방어율):
 - 안전성 지표로, 독성 점수(toxicity score)가 0.5 미만인 출력의 비율.
 - 숫자가 높을수록 안전성이 높다는 의미.
- **POS** (Positive Rate, 긍정률):
 - 감성 지표로, 긍정적인 감성을 가진 출력의 비율.
 - 숫자가 높을수록 긍정적인 감성 제어가 잘 된다는 의미.
- **FL** (Fluency, 유창성):
 - 생성된 텍스트의 언어적 품질과 가독성을 나타내는 지표 (n-gram 메트릭 사용).
 - 숫자가 높을수록 유창성이 좋다는 의미.

1. 단일 작업 결과

- **CAA, STA** (활성화 기반 방법): 안전성 제어, 감성 제어에 가장 효과적
- **LM-Steer**: 성능 들쭉날쭉
- **Promptauto**: 일관성 부족 (← 프롬프트 문장 구조나 작업 문맥에 따라 결과가 달라지므로)

2. 다중 작업 결과

- **안전성 조정 벡터**와 **감성 조정 벡터**를 합친 하나의 벡터로 두 가지 목표(안전 + 감성)를 동시에 조정 가능 → 여러 성격(목표)을 한 번에 조정하는 ‘멀티 행동 스티어링’이 가능
- 일부는 단일 작업 벡터보다 효과적